

Wk5项目总结（说人话版）

房颤风险预测系统：基于深度学习的ECG信号分析

- 一、项目背景与目标
 - 背景
 - 项目目标
- 二、数据获取与预处理
 - 1. 数据来源
 - 2. 数据处理流程
- 三、模型架构设计
 - 1. 多模态特征提取
 - 2. 序列分类器架构
- 四、创新训练策略
 - 1. 处理类别不平衡
 - 2. 两阶段训练流程
 - 3. 交叉验证与模型选择

房颤风险预测系统：基于深度学习的ECG信号分析

一、项目背景与目标

背景

房颤是最常见的心律失常类型之一，与脑卒中和心力衰竭等严重并发症密切相关。早期预测房颤风险对于预防性干预具有重大临床意义。传统方法主要依赖医生经验判断，缺乏客观量化指标。

项目目标

开发一个端到端的房颤风险预测系统，通过分析单导联心电图(ECG)信号，预测患者短期内发生房颤的风险，将患者分类为高风险或低风险两类，为临床决策提供客观依据。

二、数据获取与预处理

1. 数据来源

- MIT-BIH房颤数据库：包含长时间心电记录及房颤标记
- PAF预测挑战数据库：专为房颤预测研究设计的标准数据集

2. 数据处理流程

我们设计了一个完整的数据处理管道，包括：

2.1 信号读取与分割

- 使用wfdb库读取原始ECG信号与注释
- 识别关键数据段：前10分钟无房颤，后20分钟有/无房颤的数据
- 采用30秒滑动窗口进行数据分段，确保信息完整性

2.2 信号降噪与预处理

- Butterworth带通滤波器(0.5–40Hz)去除基线漂移和低频噪声
- IIR陷波滤波器消除50Hz工频干扰
- 信号标准化处理减少个体间差异

2.3 数据增强技术

为增强模型泛化能力，我们实现了多种增强方法：

- 添加随机噪声模拟真实环境干扰
- 时间拉伸与振幅缩放模拟不同记录条件
- 片段交换和局部反转模拟生理变异
- 生成重叠片段提升样本量及表征能力

2.4 自监督学习预训练

我们创新性地引入信号遮掩机制：

- 随机将20%采样点置零模拟信号丢失
- 训练卷积自编码器重构完整信号
- 利用预训练权重提升特征提取能力

三、模型架构设计

我们设计了一个混合特征+序列建模的深度学习架构：

1. 多模态特征提取

1.1 CNN特征提取器(SimpleConvEncoder)

- 1

特征维度：1×7500(原始) → 1×128(编码后)
- 2

关键设计：
- 3

– 三层卷积逐步提升特征抽象度
- 4

– 批标准化+ReLU激活确保训练稳定
- 5

– 全局池化获取固定维度表征

1.2 心率变异性分析(HRV特征)

- 1

基于R峰检测计算6项关键指标：
- 2

– 时域指标：mean_rr, sdnn, rmssd, nn50, pnn50
- 3

– 频域指标：lf_hf功率比
- 4

增强算法针对性改进：
- 5

– 优化R峰检测阈值与波峰突出度
- 6

– 强化异常值过滤机制

2. 序列分类器架构

2.1 双层LSTM网络

- 1

输入：134维混合特征序列(128维CNN+6维HRV)
- 2

结构设计：
- 3

– 双向LSTM捕获时序依赖关系
- 4

– 双层结构增强对长期依赖的建模能力
- 5

– 隐藏层维度128确保表征能力

2.2 输出与校准层

- 1

特征聚合：自适应平均池化整合时序信息
- 2

分类器：线性全连接层映射到二分类概率
- 3

概率校准：温度缩放机制提升预测置信度可靠性

四、创新训练策略

1. 处理类别不平衡

1.1 Focal Loss优化

```
1 class FocalLoss(nn.Module):  
2     def __init__(self, alpha=0.25, gamma=2.0):  
3         #  $\gamma$ 参数增强对困难样本的关注度  
4         #  $\alpha$ 参数平衡正负类权重
```

1.2 加权采样机制

- 正类(高风险)样本权重提升2.5倍
- 根据类别分布动态调整采样策略

2. 两阶段训练流程

2.1 阶段一：LSTM训练，CNN冻结

- 使用预训练CNN权重减少过拟合风险
- 聚焦于时序模式学习
- 使用ReduceLROnPlateau调度器，F1作为调度指标

2.2 阶段二：整体微调

- 解冻CNN进行端到端微调
- 差异化学习率设计：
 - LSTM: $2e-4$ (较高)
 - CNN: $5e-6$ (较低, 防止过拟合)
- 循环学习率帮助跳出局部最优

3. 交叉验证与模型选择

- 5折分层交叉验证确保评估可靠性
- 综合指标评估，特别关注F1分数
- 保存各折最佳模型，最终选择F1最高模型